

Algoritmo SVD (Reto Netflix)

Consultar el artículo 'KDD Cup 2007

Task 1 Winner Report' coautorado por

Miklós Kurucz y responder detalladamente cómo se logró resolver el Reto Netflix a partir de SVD.

La entrada es una matriz $user \times movie$ denotada como W . Está llena de 0s y 1s.

Un 1 significa que el usuario calificó esa película, un 0 significa que no lo hizo.

La matriz es enorme y es muy dispersa (está en su mayor parte vacía).

Temas $\leftrightarrow$ Temáticas $\leftrightarrow$ Películas

Usamos la misma idea del Análisis Semántico Latente (LSA) utilizado en la minería de texto, donde una matriz de documents $\times$ terms se divide en temas latentes (ocultos).

Problema en LSA:

Documentos

$\rightarrow$

Términos

$\rightarrow$

Temas latentes

$\rightarrow$

Problema de Netflix:

Usuarios

Películas

Temáticas latentes

$\downarrow$

(patrones de gusto ocultos)

"Documento contiene el tema X"

$\rightarrow$

"Usuario tiene gusto por la temática X"

"Término pertenece al tema X"

$\rightarrow$

"Película pertenece a la temática X"

Al igual que un documento es una combinación de temas, un usuario es una combinación de temáticas ocultas (ej: le gusta la acción, le gusta el drama). Además, así como un término pertenece a ciertos temas, una película pertenece a ciertas temáticas. Por cierto, nadie etiqueta esas temáticas a mano, el SVD las descubre automáticamente.

SVD descompone la matriz W en 3 matrices:

$$W = U^T \Sigma V$$

donde:

- U mapea cada usuario con su combinación de temáticas
- V mapea a cada película con su perfil de temáticas

- Σ indica qué tan importante es cada temática en términos generales

Usar las matrices completas solo memorizaría los datos. En su lugar, los autores decidieron conservar únicamente las $k=10$ temáticas principales, lo que fuerza al modelo a generalizar en lugar de sobreajustarse.

La puntuación de predicción para un par usuario - película es simplemente el producto escalar entre el vector de la película, exactamente igual que medir la superposición de temas entre un documento y un término en LSA.

Los pares del conjunto de entrenamiento no se seleccionaron al azar: algunos pares tenían mayor probabilidad de ser incluidos que otros. Por lo tanto, en lugar de un SVD convencional, los autores minimizaron un error reponderado, escalando cada entrada por

$$\sqrt{\text{sampling probability}}$$

antes de ejecutar SVD. Esto evita que el muestreo sesgado distorsione cuáles temáticas terminan siendo descubiertas.

Graficaron las puntuaciones reconstruidas para los pares que sí fueron calificados frente a los que no lo fueron. Las

dos distribuciones estaban claramente separadas, lo que confirmó que las 10 temáticas ocultas realmente capturan si "el gusto de este usuario coincide con esta película".

SVD se combinó con otros tres predictores mediante regresión lineal:

$$0.5533 \cdot p_{um} + 0.029 \cdot \text{correlation} \\ + 0.1987 \cdot \text{SVD} - 0.0121 \cdot \text{assoc_rules} - 0.0042$$

SVD obtuvo el segundo peso más alto, lo que confirmó que la estructura de temáticas latentes aportó un valor predictivo real más allá de los conteos simples de popularidad.