

Ejercicios Perceptron

Ejercicio 1.2:

Exercise 1.2

Suppose that we use a perceptron to detect spam messages. Let's say that each email message is represented by the frequency of occurrence of keywords, and the output is +1 if the message is considered spam.

- (a) Can you think of some keywords that will end up with a large positive weight in the perceptron?
- (b) How about keywords that will get a negative weight?
- (c) What parameter in the perceptron directly affects how many borderline messages end up being classified as spam?

(a) "free", "win", "king", "nigerian", "urgent",
"buy", "offer", "discount", "prize"

(b) "university", "meeting", "best regards",
"medical", "bank", "log in"

(c) El bias controla eso directamente. La decisión del perceptron es $h(x) = \text{sign}(w^T x + b)$

Cambiar b desplaza el límite de decisión sin

cambiar su orientación, por lo que determina directamente cuántos mensajes cercanos al límite caen a cada lado.

Ejercicio 1.3:

Exercise 1.3

The weight update rule in (1.3) has the nice interpretation that it moves in the direction of classifying $x(t)$ correctly.

- (a) Show that $y(t)w^T(t)x(t) < 0$. [Hint: $x(t)$ is misclassified by $w(t)$.]
- (b) Show that $y(t)w^T(t+1)x(t) > y(t)w^T(t)x(t)$. [Hint: Use (1.3).]
- (c) As far as classifying $x(t)$ is concerned, argue that the move from $w(t)$ to $w(t+1)$ is a move 'in the right direction'.

(a) Dado que $x(t)$ está mal clasificado por $w(t)$, el signo predicho no coincide con la etiqueta real:

$$\text{sign}(w^T(t)x(t)) \neq y(t)$$

Esto significa que $w^T(t)x(t)$ y $y(t)$ tienen signos opuestos. Como $y(t) = \pm 1$, multiplicar una cantidad por algo de signo opuesto

hace que el resultado sea negativo:

$$y(t) w^T(t) x(t) < 0$$

(b) Usando la regla de actualización:

$$\begin{aligned} w^T(t+1) x(t) &= (w(t) + y(t) x(t))^T x(t) \\ &= w^T(t) x(t) + y(t) x^T(t) x(t) \end{aligned}$$

Multiplicando ambos lados por $y(t)$ y

usando $y(t)^2 = 1$:

$$y(t) w^T(t+1) x(t) > y(t) w^T(t) x(t)$$

(c) $y(t) w^T(t) x(t)$ es una puntuación de clasificación con signo: es negativa

cuando $x(t)$ está mal clasificado y sería positiva si se clasificara correctamente.

La parte (a) muestra que esta cantidad comienza siendo negativa y la parte (b)

muestra que la actualización la incrementa estrictamente.

Entonces, aunque una sola actualización no sea suficiente para desplazar $x(t)$ al 'lado correcto', siempre empuja la puntuación de ese punto específico más cerca de una clasificación correcta.

Preguntas adicionales

- ¿El algoritmo encuentra los parámetros correctos? (¿Separa bien los datos?)

Sí. (Si los datos son linealmente separables). Si existe algún w^* que clasifique todos los puntos correctamente, entonces se garantiza que el PLA encontrará un

hiperplano separador.

- ¿El algoritmo para en un número finito de pasos? (¿Cómo garantizar convergencia?)

Sí. Si los datos son linealmente separables el Teorema de Convergencia del Perceptrón garantiza que el PLA se detiene después de un número finito de actualizaciones. Veamos esto:

Sea w^* un vector separador con

margen $\rho = \min_n y_n w^{*T} x_n > 0$ y

sea $R = \max_n \|x_n\|$. Cada actualización

aumenta la alineación $w(t)^T w^*$ en

al menos ρ , por lo que crece al

menos de forma lineal respecto a t .

Cada actualización aumenta la alineación $w(t)^T w^*$ en al menos ρ por lo que crece al menos de forma lineal respecto a t . Cada actualización aumenta $\|w(t)\|^2$ en como máximo R^2 , así que $\|w(t)\|$ crece como máximo a ritmo de $\sqrt{t}$. Dado que:

$$\cos(\text{ángulo}) = \frac{w(t)^T w^*}{\|w(t)\| \|w^*\|} \leq 1$$

y el numerador crece linealmente mientras el denominador crece a ritmo de $\sqrt{t}$,

esto fuerza una cota:

$$t \leq \frac{R^2 \|w^*\|^2}{\rho^2}$$

Por lo tanto, el número de actualizaciones es finito y acotado. El algoritmo debe detenerse.

- ¿Por qué funciona?

Cada vez que el PLA realiza una actualización, utiliza un punto que esté mal clasificado para dar un "empujón" al vector de pesos, de modo que la puntuación de ese punto en particular mejore (como ya vimos en el ejercicio 1.3).

La prueba de convergencia demuestra que estos empujones no pueden continuar para siempre sin que el vector de pesos se alinee cada vez mejor con algún separador válido w^* . La alineación crece de forma constante,

mientras que la magnitud del vector no puede crecer lo suficientemente rápido como para 'engañar' esa alineación indefinidamente.

Entonces, cada corrección local y greedy se acumula en un progreso global hacia un hiperplano que clasifica todo correctamente, precisamente porque existe un hiperplano que clasifica todo correctamente, justo porque existe un hiperplano separador hacia el cual converger. Sin separabilidad, no existe tal w^* hacia el cual converger, y la garantía deja de cumplirse.