

$$H(x) = - \sum_{i=1}^n P(X=i) \log_2 P(X=i)$$

↓

Esta es la fórmula de la entropía.

Hagamos un par de pruebas para entenderla mejor.

① Probar que $-\log_2 P(X=i)$ es la cantidad de preguntas binarias que se necesitan para representar un mensaje con esa probabilidad

Divagaciones iniciales:

Analicémoslo usando teoría de la información.

Una pregunta binaria es una pregunta que solo admite dos respuestas y las dos son mutuamente excluyentes, como por ej. las preguntas de sí o no.


Una pregunta binaria óptima es aquella que aporta la mayor cantidad de información posible: esto ocurre cuando la pregunta divide a la

mitad el espacio de probabilidad.

ej. Supongamos que queremos adivinar un número del 1 al 8.


- La pregunta binaria "¿Es el 1?" no es óptima, pq podría tomarte hasta 7 preguntas hallar el número

Espacio de probabilidad



- La pregunta binaria "¿Es mayor a 4?"

sí es óptima pq sin importar la respuesta, siempre vas a dividir la cantidad de candidatos a la mitad.




Ahora, analicemos la ganancia en términos de bits. Cuando reduces el espacio de probabilidad a la mitad eso es 1 bit, y cada división por la mitad subsecuente cuenta como 1 bit más.

• Sea $P(X=i) = p$

↳ ej $P(\text{O} = \text{mujer}) = 0.5$ en un mundo teórico.


Analicemos la cantidad de bits de info. que ganamos para distintos valores de p .

Para $p = 0.5 = \frac{1}{2}$:




1 bit

Para $p = 0.25 = \frac{1}{4}$:



2 bits




Para $p = 0.125 = \frac{1}{8}$:




3 bits

Nota: entre más improbable sea una ocurrencia (menor sea p), más bits de información dará.

- Ahora analicemos los bits como potencias de 2:



- Esto es lo mismo que hacer varias preguntas binarias óptimas, una después de la otra:



Como en una pregunta binaria óptima $p=0.5$ siempre entonces cada pregunta divide a la mitad el espacio de probabilidad.

→ Hacer 1 preg. binaria óptima me da 1 bit

→ Hacer 2 preg. binarias óptimas me da 2 bits

→ Hacer 3 preg. binarias óptimas me da 3 bits

⋮

¡Los bits de información son iguales a la cantidad de preguntas binarias óptimas que hagamos!

- Ahora deduzcamos una fórmula para hallar la cantidad de preguntas binarias óptimas que necesito para descubrir un evento que tiene probabilidad p de ocurrir.

$I(p) = \#$ de preguntas binarias óptimas que necesito para decodificar un mensaje con probabilidad de ocurrencia p

Como ya vimos, también tenemos que

$I(p) = \#$ de bits que ganamos preguntando $\{X=i\}$, dado $P(X=i)=p$

Entonces, I debe cumplir:

$$\begin{cases} I(\frac{1}{2}) = 1 \\ I(\frac{1}{4}) = 2 \\ I(\frac{1}{8}) = 3 \end{cases}$$

Deduciendo la fórmula:

$$\frac{1}{8} \xrightarrow{I} 3$$

$$\log_2\left(\frac{1}{8}\right) = -3$$

$$-\log_2\left(\frac{1}{8}\right) = 3$$

$$I(p) = -\log_2(p)$$

Demostración más formal:

Supongamos que el mensaje i tiene una proba-

bilidad p :

$$P(X=i) = p$$

Plantearemos las preguntas binarias óptimas como un árbol binario de decisión.

- La raíz es la probabilidad total 1.
- Cada bifurcación es una pregunta binaria óptima y por lo tanto divide el espacio de probabilidad del nodo padre a la mitad.
- Un nodo a una profundidad k (después de k preguntas) representa una fracción del espacio de probabilidad de 2^{-k}

Si nuestro mensaje i requiere I preguntas binarias óptimas para encontrarlo entonces estará a una profundidad I en el árbol:

$$p = 2^{-I}$$

Ahora hallemos la fórmula de I dado p :

$$\log_2(p) = \log_2(2^{-I})$$

$$\log_2(p) = -I$$

$$I = -\log_2(p)$$

Así,

$$I(p) = \begin{array}{l} \# \text{ de preguntas binarias óptimas que} \\ \text{necesito para decodificar un mensaje con} \\ \text{probabilidad de ocurrencia } p \end{array} = -\log_2(p)$$

□

② Demostrar por qué se puede expresar la entropía de una variable aleatoria mediante la fórmula $H(X) = -\sum_{i=1}^n P(X=i) \log_2(P(X=i))$

Ya demostramos que la cantidad de información o el número de preguntas binarias óptimas necesarias para un evento i con probabilidad $P(X=i)$ es $I(X=i) = -\log_2(P(X=i))$

Ahora queremos saber cuántas preguntas binarias necesitamos en promedio para hallar cualquier valor que pueda tomar la variable X . Ya no nos centramos en $X=i$ para un i específico, sino en $X=i$ para todo i posible.

Vamos a plantear un promedio ponderado que será el valor esperado de información.

El valor esperado de una función $g(X)$ es:

$$E[g(X)] = \sum_{i=1}^n P(X=i) g(X=i)$$

Aplicándolo a nuestra función de información:

$$\begin{aligned} E[I(X)] &= \sum_{i=1}^n P(X=i) I(X=i) \\ &= \sum_{i=1}^n P(X=i) (-\log_2 P(X=i)) \\ &= - \sum_{i=1}^n P(X=i) \log_2 P(X=i) \end{aligned}$$

Como la entropía es el valor esperado de la información, entonces tenemos:

$$H(X) = - \sum_{i=1}^n P(X=i) \log_2 P(X=i)$$

Es la suma ponderada de...

la probabilidad de ocurrencia de cada evento...

por la información que da ese evento (o la cantidad de preg. binarias que se necesitan para hallar ese evento).

