

Entre los parámetros ϵ y δ , ¿cuál controla de una mejor manera el número de datos N ?

Probably Approximately Correct

Veamos la definición del límite de PAC learning expresada mediante la Cota de Generalización de Hoeffding:

$$\Pr[|E_{\text{in}}(g) - E_{\text{out}}(g)| \geq \epsilon] \leq \delta$$

$$\text{con } \delta = 2Me^{-2N\epsilon^2}$$

- ϵ es el margen de error
 - δ es la probabilidad de que la estimación falle
- ¿Qué parámetro (ϵ o δ) controla el número de muestras N de forma más eficiente?

Despejemos N en función de ϵ y δ :

$$\delta = 2M e^{-2N\epsilon^2}$$

$$\frac{\delta}{2M} = e^{-2N\epsilon^2}$$

$$\ln\left(\frac{\delta}{2M}\right) = -2N\epsilon^2$$

$$\ln\left(\frac{2M}{\delta}\right) = 2N\epsilon^2$$

$$N = \frac{1}{2\epsilon^2} \ln\left(\frac{2M}{\delta}\right)$$

Analizamos el comportamiento de N respecto a cada parámetro:

- Respecto a ϵ :

$$N \propto \frac{1}{\epsilon^2}$$

→ Es cuadrático inverso

→ Es MUY costoso en cantidad de datos

ej: para reducir el error ϵ a la mitad la

cantidad de datos debe multiplicarse por 4

- Respecto a δ :

$$N \propto \ln\left(\frac{1}{\delta}\right)$$

→ Es logarítmico

→ Es mucho más barato en cantidad de datos = D

ej: para dividir a δ entre 1000 solo se necesitan $\ln(1000) \approx 6.9$ datos más.

Conclusión:

El parámetro δ controla a N de una manera mucho más eficiente que ϵ .

Esto quiere decir que exigir más certeza en la estimación es más barato (en cantidad de datos) que reducir el margen de error deseado.